Санкт-Петербургский государственный университет
Кафедра, на которой работает научник

Разработка системы извлечения и анализа связей между сущностями из фандомных источников

СЛЕПЦОВА Вера Валерьевна, группа 25.Б83-мм

Научный руководитель: Научный сотрудник лПИИ СПб ФИЦ РАН,
Старший преподаватель кафедры информатики СПбГУ, Анастасия Андреевна Корепанова
Консультант: Инженер по разработке в Сбере, Гончаров Ян Аркадьевич

Санкт-Петербург
2026

Актуальность и проблема

- Фандомные вики содержат тысячи страниц с персонажами и локациями.
- Ручной анализ связей (кто с кем встречается, где кто бывает) очень трудоёмок.
- Существующие инструменты либо не выделяют сущности автоматически, либо привязаны к одному сайту.

Цель и задачи

Цель: разработать систему извлечения персонажей и локаций из текстов фандомной вики, загрузки в базу данных и аналитических SQL-запросов.

Задачи:

- Создать парсер с возможностью смены фандома.
- Настроить извлечение сущностей (NER) с присвоением уникальных ID.
- Загрузить данные в PostgreSQL.
- Написать SQL-запросы для вопросов: топ персонажей локации, локации персонажа, часто вместе, документы по сущности.
- Построить граф совместных упоминаний персонажей.

Архитектура системы

Парсер (Python) $\rightarrow$ CSV $\rightarrow$ Извлечение сущностей (spaCy) $\rightarrow$ CSV $\rightarrow$ PostgreSQL $\rightarrow$ SQL-запросы + граф

Парсер (бэкенд)

- Абстрактный класс `BaseParser` задаёт интерфейс.
- Конкретные реализации:
  - `LotrParser` (20 страниц: 10 персонажей + 10 локаций)
  - `LadybugParser` (15 страниц: 10 персонажей + 5 локаций)
- Для смены фандома – заменить одну строку в `run_parser.py`.
- Библиотеки: `requests`, `BeautifulSoup4`, `pandas`.

Извлечение сущностей (DS-часть)

- Модель spaCy `ru_core_news_sm`.
- Проблема: стандартная модель плохо распознаёт фандомные имена (персонажи как `LOC`).
- Решение: фильтр по типам `['PER', 'LOC']`.
- Каждой сущности присваивается уникальный ID.
- Результат: `entities.csv` (имя, тип, ID, частота) и `doc_entities.csv` (связи).

База данных и импорт

- Таблицы: `documents`, `entities`, `doc_entities`.
- `doc_id` – автоинкремент (`SERIAL`).
- Импорт CSV через DataGrip.

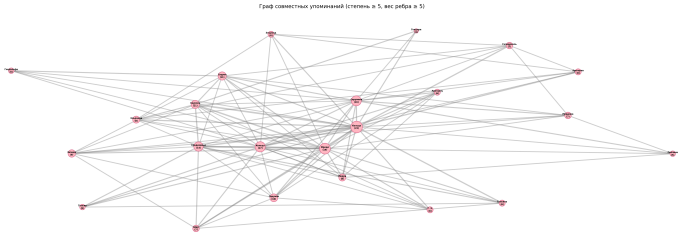
SQL-запросы (пример для LOTR)

Топ-10 персонажей локации 'Мордор':

```
WITH docs_with_mordor AS (
    SELECT de.doc_id
    FROM doc_entities de
    JOIN entities e ON de.entity_id = e.entity_id
    WHERE e.entity_name = 'Мордор' AND e.type = 'LOC'
)
SELECT e.entity_name, COUNT(*) AS mentions
FROM doc_entities de
JOIN entities e ON de.entity_id = e.entity_id
WHERE de.doc_id IN (SELECT doc_id FROM docs_with_mordor)
  AND e.type = 'PER'
GROUP BY e.entity_name
ORDER BY mentions DESC
LIMIT 10;
```

Граф совместных упоминаний

- Построен на основе `doc_entities.csv` и `entities.csv`.
- Вершины – персонажи (`PER`), рёбра – совместные документы, вес – количество таких документов.
- Фильтрация: степень >= 5, вес ребра >= 5.
- Результат: исходный граф (256 вершин, 11896 рёбер) → после фильтрации: (23 вершины, 107 рёбер).
- Крупные узлы (Фродо, Гэндальф, Саурон, Арагорн) – центральные персонажи.



Результаты

- Разработана расширяемая система извлечения сущностей.
- Проведён успешный парсинг двух фандомов (LOTR, Ladybug).
- Данные загружены в PostgreSQL, SQL-запросы дают осмысленные ответы.
- Построен граф совместных упоминаний, выделены ключевые персонажи.
- Смена фандома требует только нового класса парсера.
- Исходный код доступен в репозитории `https://github.com/s-vera666/fandom_wiki_parser`.

Заключение

- Цель достигнута, все задачи выполнены.
- Система готова к практическому использованию.
- В перспективе – нормализация падежей, семантический поиск.

Спасибо за внимание!